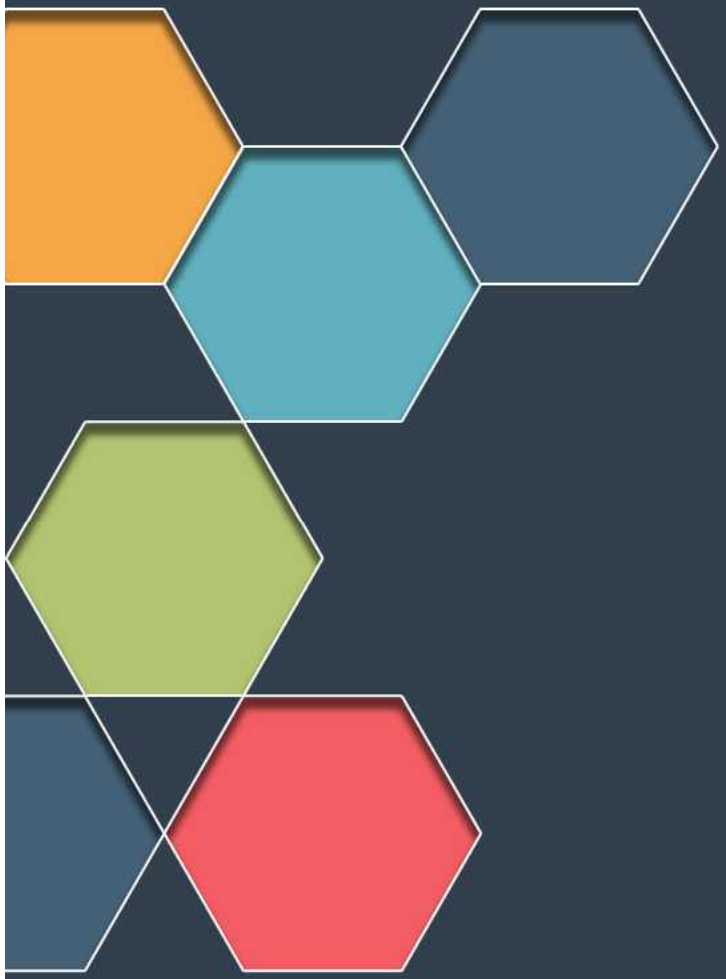


제7장 불확실성

학습 목표

- 불확실성을 확률과 조건부 확률로 표현한다.
- 베이즈 정리로 관측 후 숨은 상태의 믿음을 갱신한다.
- 시간에 따른 추정과 기대 효용에 기반한 행동을 설명한다.
- MYCIN 확신도와 확률의 의미를 구별한다.

01 불확실성

- 고전 논리는 주어진 전제가 참일 때 추론의 참 보존을 다룬다.
- 게임의 숨은 상태와 센서 관측에는 불확실성이 있다.
  - 예: 발소리가 들려도 적이 반드시 근처에 있지는 않다.
- 확률 모델은 불확실한 상태에 대한 믿음을 갱신한다.

불확실성의 예

- 집에서 공항까지 가서 탑승하는 문제
  - 중간에 자동차가 고장 날 수도 있고,
  - 엄청난 차량 정체를 겪을 수도 있다.
  - 공항이 몹시 혼잡하여서 수속에 시간이 많이 걸릴 수도 있다.

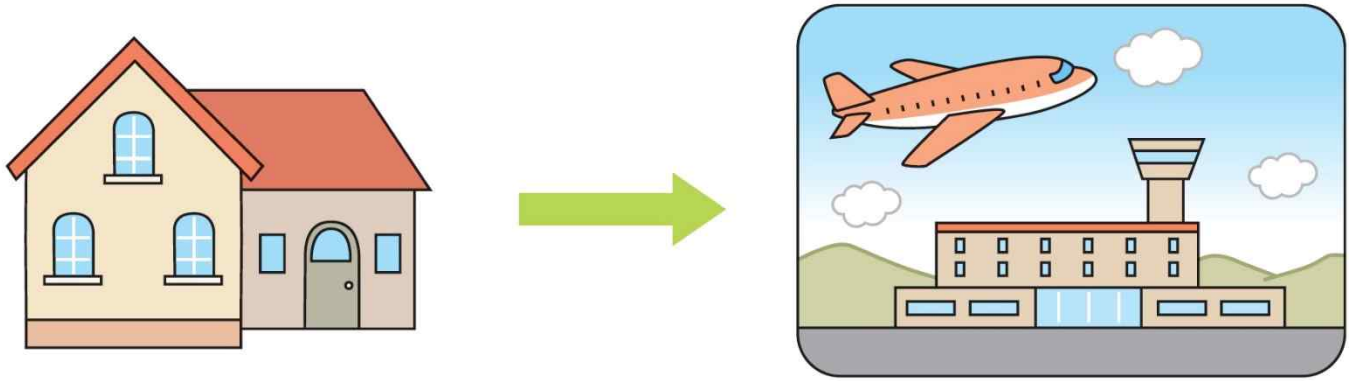


그림 7-1 불확실성이 발생하는 문제

불확실성은 왜 발생하는 것인가?

- 데이터의 불확실성: 센서로부터 얻는 데이터는 장치의 측정 오류나 오차 때문에 완전하지 못하다.
- 지식의 불완전성: 전문가로부터 얻는 지식은 완전하지 않을 수 있다. 문제 영역 자체가 불확실할 수도 있다. 예를 들어서 주식 예측이나 부동산 투자의 경우에는 문제 자체에 불확실성이 존재한다.
- 전문가들의 관점이 다른 경우: 전문가들마다 의견이 다를 수 있다.
- 정보 획득의 불완전성: 정보 자체를 모두 수집하거나 처리할 수 없기 때문에 불확실성이 발생한다. 예: 자율주행의 환경 정보
- 부정확한 언어: 인간이 사용하는 자연어에는 모호한 단어가 많다.

게임 AI에서 불확실성은 어디서 오는가?

숨은 상태: 적의 위치와 의도를 직접 볼 수 없다.

관측 오차: 발소리와 시야 센서에는 누락과 오경보가 있다.

무작위 결과: 공격의 명중이나 전리품 결과가 달라진다.

AI는 관측으로 믿음을 갱신하고 행동을 선택한다.

인공지능 시스템에서의 불확실성 처리

- 불확실한 정보에서도 게임 AI는 행동을 결정해야 한다.
- 확률은 숨은 상태에 대한 믿음을 수치화한다.
- 베이즈 추론은 새 관측으로 믿음을 갱신한다.
- 확신도 CF는 규칙 기반 지지의 정도를 표현한다.

02 확률을 이용한 불확실성 처리

- 확률 P(A)는 사건 A에 대한 불확실성을 0에서 1로 표현한다.
- 상호 배타: $P(A \cap B)=0$. 동시에 일어날 수 없다.
- 독립: $P(A|B)=P(A)$, 따라서 $P(A \cap B)=P(A)P(B)$.
- 조건부 확률: $P(A|B)=P(A \cap B)/P(B)$, $P(B)>0$.
- 상호 배타라도 $P(B)>0$이면 $P(A|B)=0$으로 정의된다.



실습: 상호 배타인가, 독립인가?

A: 한 번의 전리품 추첨에서 희귀 등급 획득

B: 같은 추첨에서 전설 등급 획득

C: 다음 전투에서 첫 번째 공격 명중

D: 독립 난수로 판정한 두 번째 공격 명중

A와 B, C와 D의 관계를 각각 판단하라.

조건부 확률

- p(A|B)
  - 사건 B가 발생했을 때, 사건 A가 발생할 확률
- p(A∩B)
  - A와 B의 결합 확률
  - A와 B가 동시에 발생할 확률

사전 확률과 사후 확률

$$p(A|B) = \frac{A\text{와 } B\text{가 동시에 발생할 경우의 수}}{B\text{가 발생할 경우의 수}}$$

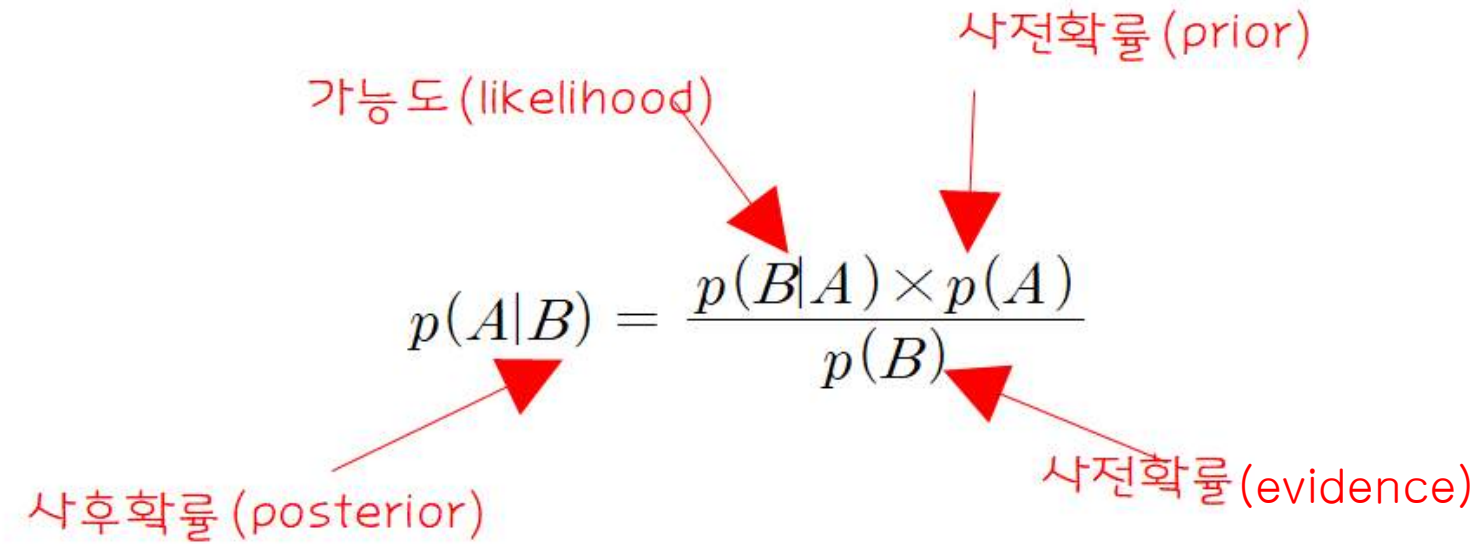
$$p(A|B) = \frac{p(A \cap B)}{p(B)}$$

$$p(B|A) = \frac{p(A \cap B)}{p(A)}$$

$$p(A \cap B) = p(B|A) \times p(A)$$

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

베이즈 규칙 (Bayes Rule)



베이즈 정리: P(A|B)=P(B|A)P(A)/P(B)

P(B|A)는 가능도, P(A)는 사전확률이다.

P(A|B)는 관측 B 뒤의 사후확률이다.

베이즈 정리의 분모는 어디서 오는가

H와 ¬H가 전체 경우를 나누면

$$P(E)=P(E|H)P(H)+P(E|\neg H)P(\neg H)$$

따라서 $P(H|E)=P(E|H)P(H)/P(E)$

분모 P(E)는 E가 관측될 전체 확률

가능도와 사후확률을 구별하기

P(발소리|왼쪽)=0.75: 왼쪽일 때 들릴 비율

P(왼쪽|발소리)=0.652: 듣고 난 뒤 왼쪽일 믿음

순서를 뒤집을 때 사전확률과 오경보율이 필요

P(E|H)와 P(H|E)는 일반적으로 다르다

베이즈 정리

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

$$p(B) = p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)$$



$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)}$$

베이즈 갱신: 경비 NPC의 발소리

숨은 상태 H: 적이 왼쪽 통로에 있다. $P(H)=0.20$

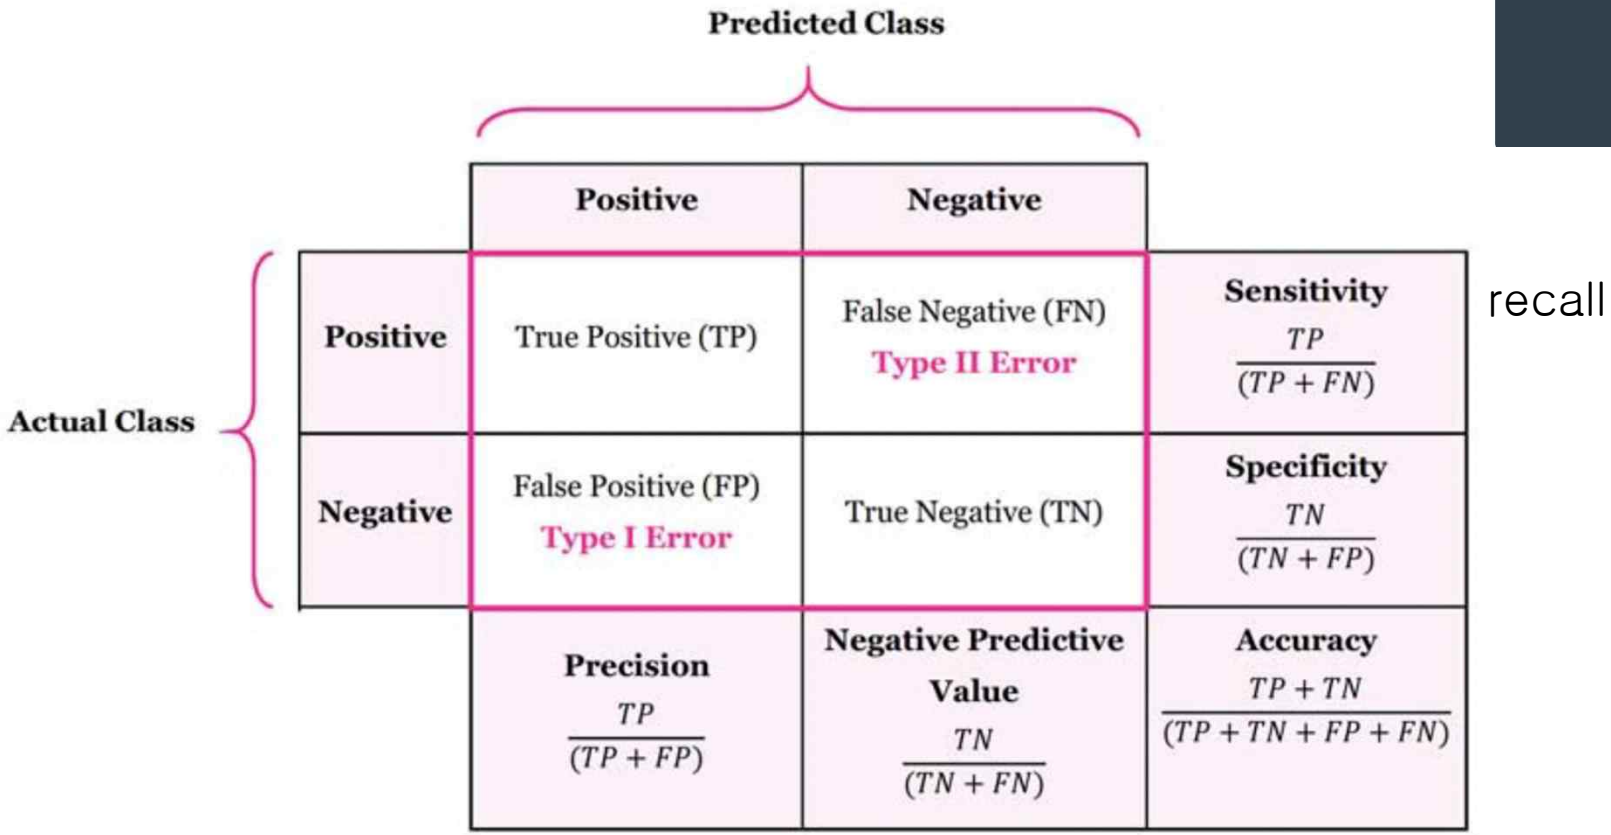
관측 S: 왼쪽에서 발소리가 들린다.

$P(S|H)=0.75$, $P(S|\neg H)=0.10$

$P(H|S)=0.75\times0.20 \,/\, (0.75\times0.20+0.10\times0.80)$

관측 후 왼쪽 통로의 확률은 약 0.652이다.

Confusion Matrix



recall

- Recall(재현율, 민감도): 얼마나 실제 참이 예측되었는가? 실제 True 중 모델이 True 로 예측한 비율
- Precision(정밀도): 얼마나 예측이 실제 참을 찾아내는가? 모델이 True 라고 한 것 중 실제 True 비율
- Specificity(특이도): 실제 negative 중 negative로 맞게 판정하는 비율

- F1 Score
  - **정밀도(Precision)와 재현율(Recall)의 조화평균(Harmonic Mean)**
  - **F1 Score = 2 * (Precision * Recall) / (Precision + Recall)**
- F1 Score는 다음과 같은 상황에서 **특히 유용**
  - **데이터 불균형(Imbalanced Data)이 심할 때**
    - 예: 스팸 메일 분류 (스팸 1%, 정상 메일 99%). 단순히 '정상메일'이라고만 예측해도 정확도(Accuracy)는 99%지만, 이는 무의미함. F1 Score는 스팸을 찾아내는 성능을 제대로 평가함
  - **False Negative(FN)와 False Positive(FP) 모두 중요할 때**
    - 예: 암 진단, 금융 사기 탐지 등. (FN: 환자를 놓침, FP: 건강한 사람을 불안하게 함)
  - **정밀도와 재현율 중 하나만 높은 '치팅' 모델을 걸러낼 때**

데이터 불균형: 1,000건의 실제 계산

실제 위험 10건, 정상 990건

검출 결과: TP=8, FN=2, FP=18, TN=972

재현율=8/10=0.80, 정밀도=8/26≈0.31

F1=2TP/(2TP+FP+FN)=16/36≈0.44

재현율만 보면 오경보 18건이 드러나지 않는다

재현율·정밀도·F1 중 무엇을 볼까

놓친 위험이 치명적: 재현율을 우선 확인

잦은 오경보가 비싸다: 정밀도를 함께 확인

두 오류를 한 값으로 균형: F1을 사용

TN도 중요하면 특이도와 전체 혼동행렬을 본다

Lab: Z-바이러스 1

- 세계의 인구의 10%가 Z-바이러스에 감염되었다.
- Z-바이러스 감염자이면 90% 확률로 positive로 판정한다. 민감도 (Sensitivity). Recall (Type II error 포함)
- Z-바이러스 감염자가 아니면 70%의 확률로 negative로 판정한다. 특이도 (Specificity)
- 어떤 개인이 검사를 하였는데 positive로 나왔다면 이 개인이 좀비일 확률은 얼마나 될까?



	P	N
P	TP 0.9	FN 0.1
N	FP 0.3	TN 0.7

Lab: Z-바이러스 1

$$P(Zombie|+) = \frac{P(+|Zombie)P(Zombie)}{P(+)}$$
$$= \frac{P(+|Zombie)P(Zombie)}{P(+|Zombie)P(Zombie) + P(+|\neg Zombie)P(\neg Zombie)}$$
$$= \frac{0.90 \times 0.1}{0.90 \times 0.1 + 0.30 \times 0.90}$$
$$= 0.25$$

	P	N
P	TP 0.9	FN 0.1
N	FP 0.3	TN 0.7

Lab: 과일 문제

- 그릇 #1에는 사과 10개와 바나나 30개가 있으며 그릇 #2에는 사과와 바나나가 각각 20개가 있다. 어떤 사람이 그릇을 무작위로 골라 과일을 무작위로 선택한다고 하자. 어떤 사람이 선택한 과일이 바나나로 판명되었다. 그 사람이 그릇 #1에서 바나나를 선택했을 가능성은 얼마나 될까?



사과 10개
바나나 30개



사과 20개
바나나 20개

Lab: 과일 문제

$$p(H_1|E) = \frac{p(E|H_1) \times p(H_1)}{p(E|H_1) \times p(H_1) + p(E|H_2) \times p(H_2)}$$
$$= \frac{0.75 \times 0.5}{0.75 \times 0.5 + 0.5 \times 0.5} = 0.6$$



사과 10개
바나나 30개



사과 20개
바나나 20개

Q

- 공이 들어 있는 두 개의 항아리가 있다. 첫 번째 항아리에는 빨간 공 50개와 파란 공 50개가 들어 있다. 두 번째 항아리에는 30개의 빨간 공과 70개의 파란 공이 들어 있다. 두 항아리 중 하나가 무작위로 선택되고, 선택된 항아리에서 공을 무작위로 뽑는다. 빨간 공이 뽑혔을 때 첫 번째 항아리에서 선택되었을 확률은 얼마인가? 베이즈 규칙을 사용하여 계산하라.

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B)}$$

$$p(A|B) = \frac{p(B|A) \times p(A)}{p(B|A) \times p(A) + p(B|\neg A) \times p(\neg A)}$$

Lab: 카드 게임

- 우리가 한 장의 카드를 가지고 있는데 카드에 얼굴이 그려져 있다는 것만 알고 있다. 이 상황에서 이 카드가 킹(king)일 확률을 추론해보자. 즉 P(King | Face) 확률을 계산해보는 것이다.



Lab: 카드 게임

$$P(King|Face) = \frac{P(Face|King)P(King)}{P(Face)}$$

$$P(King|Face) = \frac{P(Face|King)P(King)}{P(Face)} = \frac{13}{3}\frac{1}{13} = \frac{1}{3}$$



둘 이상의 위치 가설

적의 위치가 A, B, C 중 정확히 하나라고 가정한다.

사전확률: $P(A)=0.5$, $P(B)=0.3$, $P(C)=0.2$

경보 가능도: $P(E|A)=0.1$, $P(E|B)=0.6$, $P(E|C)=0.8$

가중치 $P(E|H_i)P(H_i)$를 모두 더해 정규화한다.

배타적이고 빠짐없는 가설 집합일 때 이 합을 사용한다.

실습: 경보 후 적의 위치 분포

앞 장표의 사전확률과 가능도를 사용하라.

A, B, C의 정규화 전 가중치를 계산하라.

경보 후 각 방의 확률을 구하라.

가장 가능성이 높은 방은 어디인가?

IF E THEN H의 0.7은 무엇인가

가능도 $P(E|H)=0.7$은 결론 확률이 아니다

예: $P(H)=0.2$, $P(E|H)=0.7$, $P(E|\neg H)=0.3$

$P(H|E)=0.14/(0.14+0.24)\approx 0.368$

규칙의 숫자는 뜻을 먼저 정의해야 한다

03 베이즈 정리와 추론

- 규칙 IF E THEN H의 수치가 무엇을 뜻하는지 정의한다.
- P(H|E)는 증거 E가 관측된 뒤 가설 H의 확률이다.
- 사전확률 P(H)와 가능도 P(E|H), P(E|¬H)가 필요하다.
- 자료나 전문가의 판단으로 추정하고 검증한다.

베이즈 정리와 추론

$$p(H|E) = \frac{p(E|H) \times p(H)}{p(E|H) \times p(H) + p(E|\neg H) \times p(\neg H)}$$

- P(H) - 가설 H가 참일 확률(사전 확률)
- P(¬H) - 가설 H가 거짓일 확률(사전 확률)
- p(E|H) - 가설 H가 참일 때, 증거 E가 나타날 확률(가능도)
- p(E|¬H) – 가설 H가 거짓임에도, 증거 E가 나타날 확률(가능도)

위의 사전 확률과 가능도는 누가 제공해야 하는 것일까?

- 사전확률과 가능도는 자료에서 추정할 수 있다.
- 관측 데이터가 부족하면 전문가의 판단을 참고한다.
- 추정치의 근거와 오차를 기록하고 게임 로그로 검증한다.



증거와 가설이 여러 개일 때

- 여러 위치 가설 H_i에 대해 증거 E를 관측했다고 하자.
- 분모 $\Sigma_i P(E|H_i)P(H_i)$를 쓰려면 가설들이
- 서로 배타적이고 전체 경우를 빠짐없이 덮어야 한다.
- 감기와 폐렴처럼 함께 가능한 가설은 그대로 분할할 수 없다.

$$p(H_i|E) = \frac{p(E|H_i) \times p(H_i)}{\sum_{k=1}^{m} p(E|H_k) \times p(H_k)}$$

베이즈 정리의 단점

- 베이즈 추론에는 사전확률과 가능도 추정이 필요하다.
- 데이터가 부족하거나 센서 환경이 바뀌면 추정이 어려울 수 있다.
- 게임 로그와 시뮬레이션으로 모형을 갱신하고 검증한다.

베이즈 네트워크: 위치와 두 센서

H: 은신 위치 (L / R)

↙ ↘

S: 왼쪽 발소리 **V: 왼쪽 시야**

$$P(H,S,V)=P(H) \times P(S|H) \times P(V|H)$$

H를 알고 나면 두 센서의 오차가 독립이라는 모델 가정.

센서 확률표: 각 숫자를 읽는 법

S=1: 왼쪽에서 발소리　　V=1: 왼쪽 시야에서 적 감지

실제 위치	사전 P(H)	발소리 P(S=1|H)	시야 P(V=1|H)
왼쪽 L	0.30	0.80	0.70
오른쪽 R	0.70	0.20	0.10

0.20은 “오른쪽에 있는데 왼쪽 소리가 난” 경우의 가능도.

두 관측 뒤 은신 위치 갱신

① 왼쪽 가중치: 0.30 × 0.80 × 0.70 = 0.168

② 오른쪽 가중치: 0.70 × 0.20 × 0.10 = 0.014

③ 관측 전체 확률: 0.168 + 0.014 = 0.182

④ 왼쪽 사후확률: 0.168 / 0.182 ≈ 0.923

오른쪽은 0.014 / 0.182 ≈ 0.077, 두 위치의 합은 1.

위치를 모르면 두 관측은 연관된다

위치를 모를 때: $P(V=1) = .30\times.70+.70\times.10=0.28$

왼쪽 소리를 들으면: $P(L|S=1) =.30\times.80/(.30\times.80+.70\times.20)=0.24/0.38 \approx 0.632$

이때 $P(V=1|S=1) = P(S=1,V=1)/P(S=1) = .182/.38 \approx 0.479$

발소리가 H에 대한 믿음을 바꿔 시야 예측도 바뀐다.

H를 알 때의 독립과 H를 모를 때의 연관성은 함께 성립한다.

Lab:베이즈 정리로 규칙의 확률 계산

- 규칙

IF	치통이 있다.
THEN	충치이다. (확률: ???)

	치통	¬치통
충치	0.04	0.06
¬충치	0.01	0.89

Confusion Matrix 아님

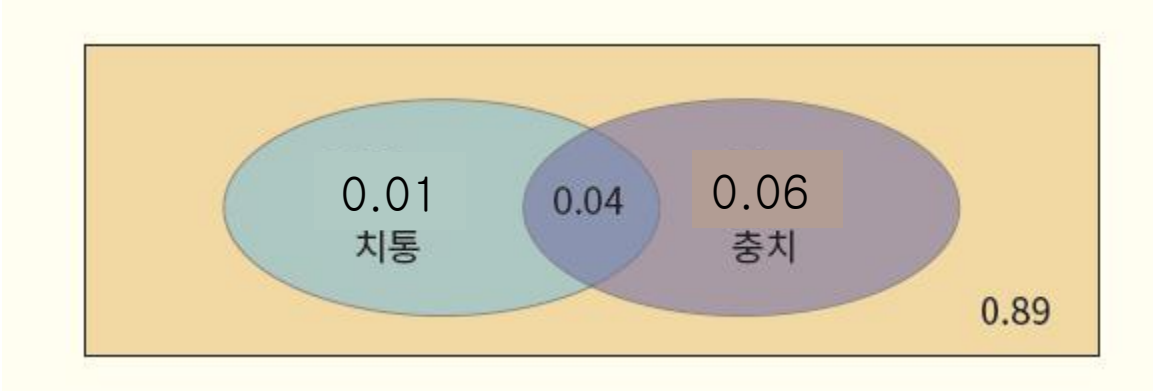
Lab:베이즈 정리로 규칙의 확률 계산 실습

$$P(\text{충치}\mid\text{치통}) = \frac{P(\text{충치}\wedge\text{치통})}{P(\text{치통})} = \frac{0.04}{(0.04+0.01)} = 0.8$$

$$P(\neg\text{충치}\mid\text{치통}) = \frac{P(\neg\text{충치}\wedge\text{치통})}{P(\text{치통})} = \frac{0.01}{(0.04+0.01)} = 0.2$$

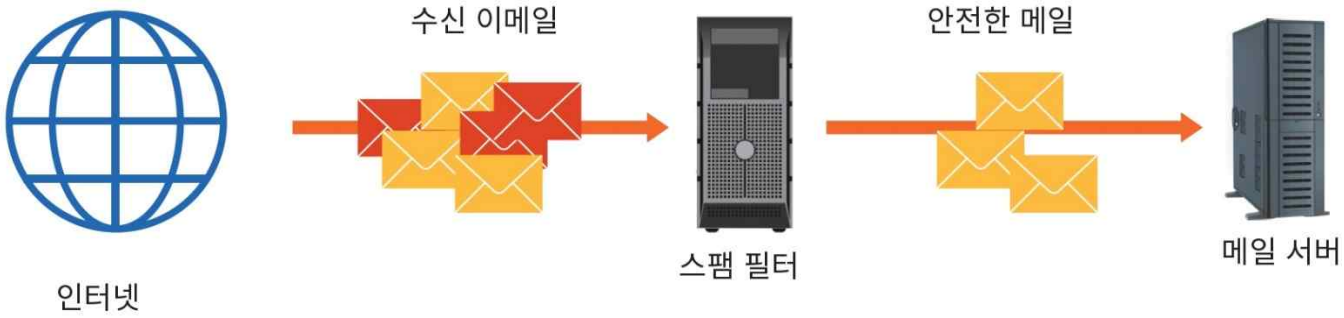
IF 치통이 있다.
THEN 충치이다. (확률: 0.8)

	치통	¬치통
충치	0.04	0.06
¬충치	0.01	0.89



Lab:스팸 필터링

- 조건부 확률 계산 P(spam|word)
- 전체 메일 중에 40%가 스팸 메일이다.
- 스팸 메일 중의 1%가 제목으로 특정한 word를 가진다.
- 정상 메일 중의 0.4%가 제목으로 특정한 word를 가진다.
- 메일의 제목에 특정 word가 있을 때 스팸일 확률은?



Lab:스팸 필터링

$$P(spam|word) = \frac{P(word|spam) \times P(spam)}{P(word|spam) \times P(spam) + P(word|\neg spam) \times P(\neg spam)}$$

- 여기서 P(spam) = 0.4 이고 P(word|spam) = 0.01이다. 또 P(word|¬spam)은 0.004, P(¬spam)은 0.6이다. 따라서 다음과 같은 결과를 얻는다.

$$\mathrm{P(spam\,|\,word)} = 0.004/(0.0064)=5/8=0.625$$

Q

- 어떤 컨설팅 회사가 경기 침체를 예측하는 수학적인 모델을 만들었다. 모델은 경기 침체가 실제로 발생할 때 80%의 확률로 경기 침체를 예측하고, 경기 침체가 없을 때 10%의 확률로 경기 침체를 예측한다. 경기 침체에 빠질 사전 확률은 20%이다. 이 모델이 경기 침체를 예측한다면 경기 침체가 실제로 일어날 확률은 얼마인가? 베이즈 규칙을 사용해서 계산하라.

	P	N
P	TP 0.8	FN 0.2
N	FP 0.1	TN 0.9

베이즈 필터: 한 턴의 순서

베이즈 필터는 시간이 흐르며 변하는, 직접 볼 수 없는 상태의 확률을 새 관측이 들어올 때마다 갱신하는 방법

현재 위치 믿음 b_t = (A 0.60, B 0.40)

① 적의 이동 T를 반영하여 다음 위치를 예측

T(s′|s)는 현재 s에서 다음 s′로 이동할 확률

② 새 경보의 가능도 O를 반영하여 믿음을 수정

O(o|s′)는 다음 위치 s′에서 새 관측 o가 나타날 가능도

$\bar{b}_{t+1}$: 경보 전 b_{t+1}: 경보 후
이동 모형으로 경보 전 분포 $\bar{b}_{t+1}$을 예측하고, 그 다음 경보 가능도를 곱한 뒤 정규화해 b_{t+1}을 구한다

매 턴 "이동 예측 → 관측 갱신"을 반복한다.

이동 확률표: 어디에서 어디로?

현재 믿음: A 0.60 B 0.40

현재 출발 / 다음 도착	A	B
A	0.70	0.30
B	0.20	0.80

각 행은 “그곳에서 출발했을 때 갈 곳”이며 합이 1이다.

이동 후의 위치: 출발지별 기여 합산

다음 위치	현재 A에서	현재 B에서	예측 확률
A	0.6×0.7=0.42	0.4×0.2=0.08	0.50
B	0.6×0.3=0.18	0.4×0.8=0.32	0.50

$$\bar{b}_{t+1}(s') = \Sigma_s \, P(s'|s) b_t(s)$$

경보를 듣기 전 예측 분포: (A 0.50, B 0.50)

경보를 들었다면: 적 위치 예측을 다시 수정

가상 100회: 이동 후 A 50회, B 50회

경보 발생: A에서 50×0.2=10회, B에서 50×0.8=40회

경보가 난 50회만 보면 A는 10회, B는 40회

새 믿음: P(A|경보)=10/50=0.20, P(B|경보)=0.80

분모는 10+40=50회; 다음 턴은 (A 0.20, B 0.80)에서 시작.

실습: 다음 턴에 경보가 없다면?

시작 믿음: A 0.20, B 0.80

이동: A→A 0.70, B→A 0.20 (나머지는 B)

관측: 경보 없음

P(무경보|A)=0.80, P(무경보|B)=0.20

이동 후와 무경보 후 A/B 확률을 각각 구해 보자.

확률에서 행동으로: 기대 효용

갱신된 위치 확률을 얻었다면 행동의 보상과 위험을 비교한다.

$EU(a)=\Sigma_s\ P(s|e)U(a,s)$

행동별 보상과 위험을 상태 확률로 가중한다.

게임 AI는 기대 효용이 가장 큰 행동을 선택할 수 있다.

실습: 공격과 퇴각 중 무엇을 택할까?

적이 앞에 있을 확률은 0.35이다.

공격 효용: 적이 있으면 +10, 없으면 −5

퇴각 효용: 적이 있으면 +2, 없으면 0

두 행동의 기대 효용을 계산하고 선택하라.

행동 선택: 공격과 퇴각 계산

P(적 있음)=0.35, P(없음)=0.65

공격 EU=0.35×10+0.65×(−5)=0.25

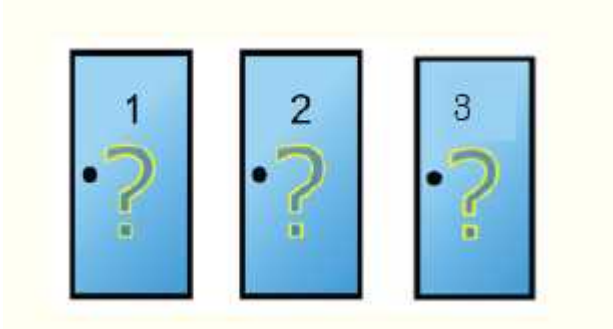
퇴각 EU=0.35×2+0.65×0=0.70

기대 효용이 큰 퇴각 선택

확률은 예측, 효용은 게임 설계의 보상·위험

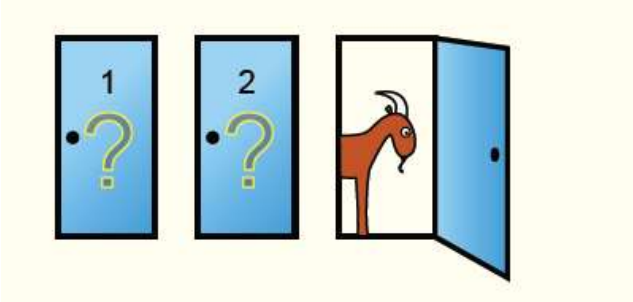
Lab: 몬티홀 문제

- 세계적인 공학자 5000명을 혼란에 빠뜨린 유명한 확률 문제가 있다. 바로 몬티 홀 문제(Monty Hall problem)이다.
- 사용자가 맞추면 상품을 주는 퀴즈쇼(Let's Make a Deal, 진행자 Monty Hall)가 있다. 이 게임쇼에서는 세 개의 문 중에서 하나를 선택할 수 있다. 하나의 문 뒤에는 자동차가 있고 다른 문들 뒤에는 염소가 있다.



Lab: 몬티홀 문제

- 사용자가 1번 문을 선택하면 그 문 뒤에 무엇이 있는지 아는 사회자(Monty Hall)가 염소가 있는 문(3번문이라고 하자.)을 연다. 그런 다음, 사회자는 당신에게 선택을 바꿀 기회를 준다.
- 선택을 바꾸는 것이 사용자에게 유리할까? 그대로 있는 것이 유리할까?



몬티홀의 핵심 가정

진행자는 자동차 위치를 안다.

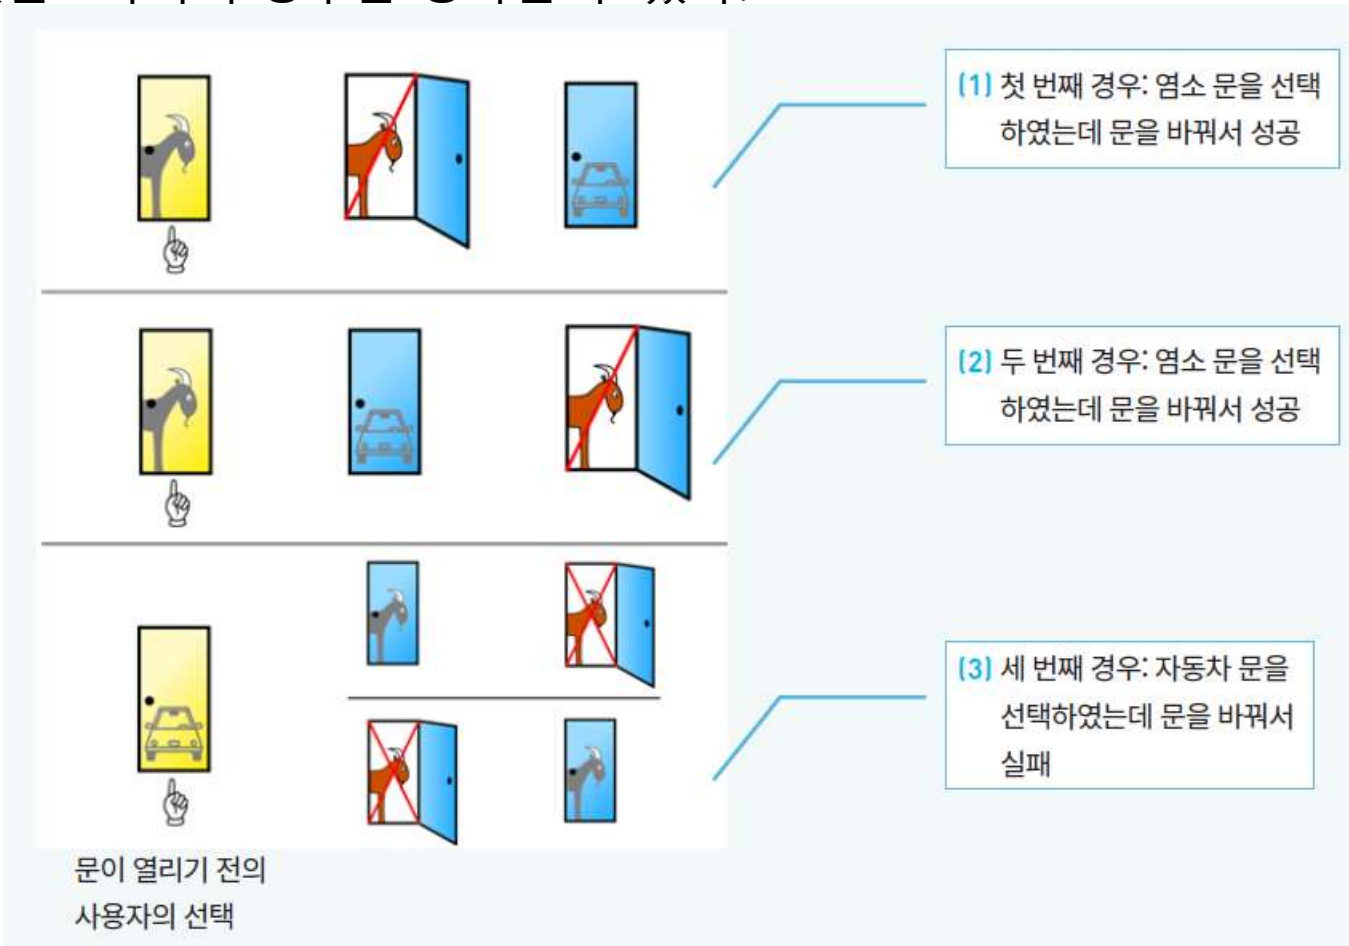
선택하지 않은 문에서 항상 염소 문을 연다.

항상 문을 바꿀 기회를 제공한다.

이 가정에서 유지 1/3, 변경 2/3이다.

Lab: 몬티홀 문제

- 직관적인 설명: 일단 참가자가1 번 문을 선택하였고 자동차가 각 문 뒤에 있었을 3가지의 경우를 생각할 수 있다.

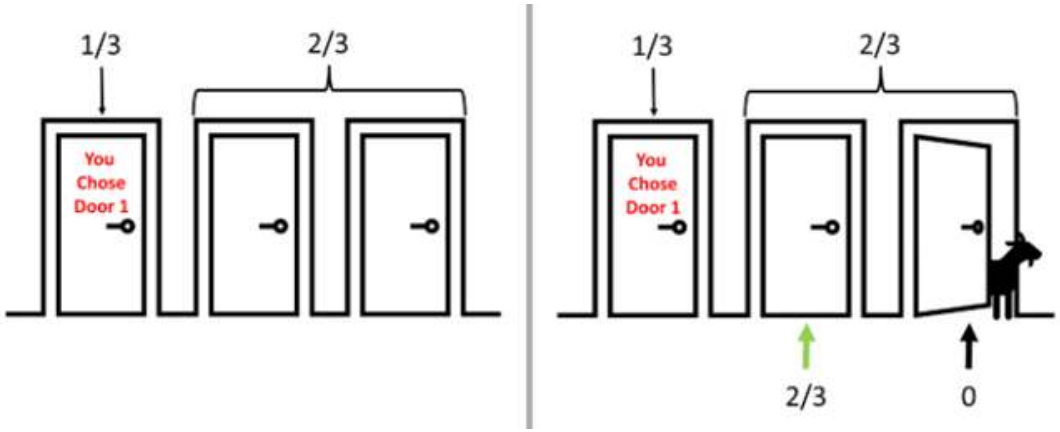


Lab: 몬티홀 문제

- 베이즈 정리를 이용해보자.

$$P(\text{문2에 자동차}|\text{사회자 문3 열음}) = \frac{P(\text{사회자 문3 열음}|\text{문2에 자동차})P(\text{문2에 자동차})}{P(\text{사회자 문3 열음})}$$

$$P(\text{문2에 자동차}|\text{사회자 문3 열음}) = \frac{1^*(1/3)}{(1/2)} = \frac{2}{3}$$



Lab: 몬티홀 문제

```
import random

NGames=10000
UnchangeGame=[]
ChangeGame=[]

for i in range(0, NGames):

    # 자동차는 랜덤하게 숨겨진다.
    CarDoor=random.choice(["Door1", "Door2", "Door3"])
    # 사용자가 첫 번째 선택을 한다.
    UserDoor=random.choice(["Door1", "Door2", "Door3"])
    # 호스트가 자동차가 있지 않은 문을 연다.
    OpenDoor=list(set(["Door1", "Door2", "Door3"])-set([UserDoor, CarDoor]))[0]
    # 남아 있는 문을 결정한다.
    OtherDoor=list(set(["Door1", "Door2", "Door3"])-set([UserDoor, OpenDoor]))[0]

    # 사용자가 선택을 바꾸지 않아서 성공하면 True를 리스트에 추가한다. True는 정수 1이다.
    UnchangeGame.append(UserDoor==CarDoor)
    # 사용자가 선택을 바꾸어서 성공하면 True를 리스트에 추가한다.  True는 정수 1이다.
    ChangeGame.append(OtherDoor==CarDoor)

# 각 리스트에서 정수 1의 개수를 센다.
print(f"{NGames} 개의 게임 중에서 바꾸지 않았을 때의 승률: {sum(UnchangeGame)/NGames} \n\
      바꾸었을 때의 승률: {sum(ChangeGame)/NGames}")
```

몬티홀 시뮬레이션 결과 읽기

처음 선택한 문에 자동차: 확률 1/3

나머지 두 문에 자동차: 확률 2/3

진행자가 반드시 염소 문을 열면 남은 문에 2/3

10,000회 모의실험은 약 1/3 대 2/3에 수렴

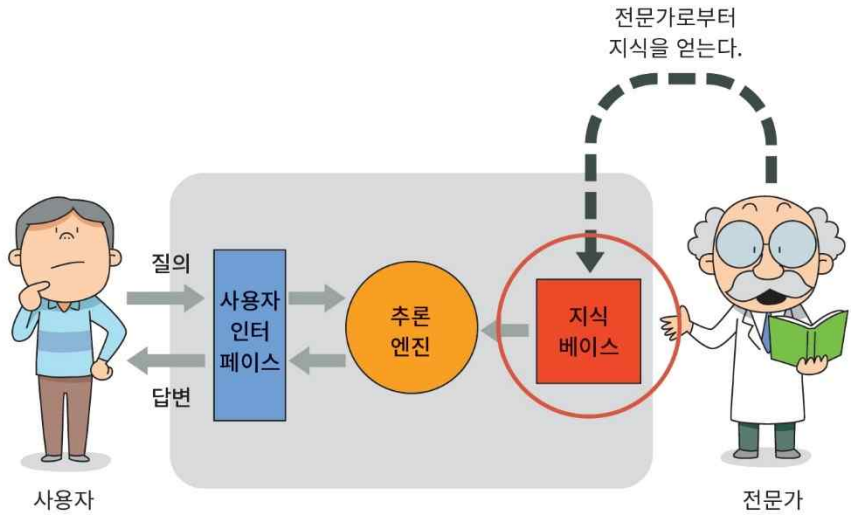
진행자의 행동 규칙을 고정해야 비교할 수 있다

Lab: 몬티홀 문제

10000 개의 게임 중에서 바꾸지 않았을 때의 승률: 0.3313
바꾸었을 때의 승률: 0.6687

04 확신도

- 베이즈 추론의 대안으로 가장 잘 알려져 있는 것은 확신도(certainty factor)이다.
- 확신도는 MYCIN이라는 전문가 시스템에서 사용됨
- MYCIN은 박테리아 감염을 진단하고 치료하는 전문가 시스템
- 확률 이론을 사용하기 위해서는 너무 많은 조건부 확률이 필요



확신도

- 확신도 CF는 규칙의 증거가 결론을 지지하는 정도이다.
- 양수는 지지, 음수는 반박, 0은 중립을 나타낸다.
- 범위는 −1에서 +1까지이다.
- CF(H,E)는 확률 P(H|E)와 같은 값이 아니다.

IF	1) The stain of the organism is gram positive, and 2) The morphology of the organism is coccus, and 3) The growth conformation of the organism is chains
THEN	There is suggestive evidence (0.7) that the identity of the organism is streptococcus

stain: 염색, morphology: 형태, coccus: 구균, conformation: 형태, streptococcus: 연쇄구균 – 화농성 감염증의 원인균

MYCIN의 CF: 확률과 다른 숫자

MB(H,E): 증거 E가 H를 지지하는 정도

MD(H,E): 증거 E가 H를 반박하는 정도

CF(H,E)=MB(H,E)−MD(H,E), 범위 [−1,1]

CF=0은 증거 부족 또는 지지·반박의 상쇄 가능

CF=0.7을 P(H|E)=0.7로 읽지 않는다

확신도의 계산

- MYCIN에서는 어떤 규칙이 점화되기 위해서는 확신도가 문턱값을 넘어야 한다. 이때 불신의 정도인 MD가 영향을 심하게 끼치게 된다.

- 예를 들어서 어떤 규칙의 MB = 0.8 이고 MD = 0.6이라고 하자. 이 규칙이 점화되기 위한 확신도의 문턱값은 0.25라고 하자. 이 규칙은 MB가 0.8이나 되지만 점화될 수가 없다. MD도 상당히 높기 때문이다.

- 이 단점을 방지하기 위하여 확신도의 정의를 다음과 같이 변경한다.
  - cf[H, E] = (MB – MD)/(1- min(MB, MD))
  - (0.8-0.6)/(1-min(0.8, 0.6)) = 0.2/0.4 = 0.5

규칙의 강도와 전건의 불확실성

IF E THEN H, 규칙 CF(H,E)=0.70

E가 확실하면 H에 기여하는 CF=0.70

E의 CF가 0.60이면 기여 CF=0.60×0.70=0.42

0.42는 결론 H의 발생 확률이 아니다

불확실한 증거를 가진 규칙에서의 확신도

- 불확실한 증거를 가진 규칙에서의 확신도
  - IF E (불확실한 증거)
  - THEN H (가설)

- cf(H, e) = cf(E, e) × cf(H, E)
- (예)
  - IF 하늘이 흐리다.(불확실한 증거)
  - THEN 비가 온다.(가설, cf=0.8)
  - cf(E, e): 불확실한 증거 e에 의한 증거 E의 확신도
  - 규칙의 전제인 "하늘이 흐리다"의 확신도가 0.6
  - cf(H, e) = cf(E, e) × cf(H, E) = 0.6 × 0.8 = 0.48

규칙이 여러 개의 전제를 가지는 경우

- AND로 연결되는 경우
  - IF E1 AND E2
  - THEN H (가설, cf)

  - $cf(H, E1 \cap E2) = \min(cf(E1), cf(E2)) \times cf(H, E)$

- OR로 연결되는 경우
  - IF E1 OR E2
  - THEN H (가설, cf)

  - $cf(H, E1 \cup E2) = \max(cf(E1), cf(E2)) \times cf(H, E)$

규칙이 여러 개의 전제를 가지는 경우

- 규칙
  - IF 하늘이 흐리다. OR 비가 온다.
  - THEN 우산을 준비한다.(cf 0.9)

- "하늘이 흐리다"의 확신도는 0.5, "비가 온다"의 확신도는 0.6
- "우산을 준비한다"는 가설의 확신도는 다음과 같이 계산할 수 있다.
  - $cf(H, E1 \cup E2) = \max(0.5, 0.6) \times 0.9 = 0.54$

같은 결론을 지지하는 규칙 둘

규칙 1의 기여 $CF_1=0.60$, 규칙 2의 기여 $CF_2=0.50$

둘 다 양수일 때: $CF=CF_1+CF_2(1-CF_1)$

따라서 $CF=0.60+0.50\times0.40=0.80$

같은 증거를 중복 세지 않도록 규칙 간 의존성을 확인한다.

찬성과 반대의 증거를 함께 고려하기

H를 지지하는 증거의 MB=0.60

H를 반박하는 증거의 MD=0.30

원래 MYCIN의 최종 CF(H)=MB−MD=0.30

지지 0.60에 반박을 반영해 확신도가 낮아짐

같은 증거를 두 번 반영하지 않도록 주의

실습: 경비 NPC의 매복 경고

발소리 증거 CF(E)=0.60

발소리이면 매복이라는 규칙 CF(H,E)=0.80

별도 단서의 매복 지지 CF_2=0.30

첫 규칙의 기여와 두 양의 CF를 결합하라.

정리: 게임 AI의 불확실성 처리

사전확률과 센서 모형으로 숨은 상태의 믿음을 갱신한다.

시간이 흐르면 이동 예측 후 새 관측을 반영한다.

행동은 상태 확률과 효용을 함께 고려해 선택한다.

CF는 규칙 기반 지지 정도이며 확률과 해석이 다르다.